



مقدمه

شما نقش یک تحلیل‌گر داده در یک استارت‌آپ فعال در حوزه فناوری املاک یا PropTech را بر عهده دارید. این شرکت در حال توسعه محصولی برای قیمت‌گذاری خودکار املاک و ارائه تصویری دقیق و به‌روز از بازار مسکن ایران است.

داده‌های اولیه پروژه شامل نزدیک به یک میلیون آگهی فروش، رهن و اجاره است؛ داده‌هایی نامنظم و ناهمگون که بدون پاک‌سازی و استانداردسازی، نمی‌توان بر مبنای آن‌ها تحلیل قابل‌اعتمادی ارائه کرد. مأموریت شما این است که این داده‌های خام را به گزارشی مستند از وضعیت بازار، روند عرضه، اختلاف قیمت میان مناطق و عوامل مؤثر بر ارزش املاک تبدیل کنید.

پیش از ورود به مرحله مدل‌سازی، لازم است کیفیت و میزان اعتبار داده‌ها ارزیابی شود. همچنین باید معیاری روشن و قابل‌دفاع تعریف شود تا امکان مقایسه منطقی آگهی‌های فروش، رهن و اجاره با یکدیگر فراهم شود.

اهداف

هدف پروژه، پاسخ‌دادن به پرسش‌های متداول زیر است:

- داده‌های آگهی تا چه اندازه کامل، صحیح و قابل‌اعتماد هستند؟
- کدام شهرها و محله‌ها گران‌تر یا ارزان‌ترند؟
- در کدام مناطق عرضه در حال افزایش یا کاهش است؟
- قیمت پیشنهادی مسکن در ماه‌های موردبررسی چه روندی داشته است؟

- چگونه می‌توان آگهی‌های فروش، رهن و اجاره را بدون ترکیب نادرست رژیم‌های قیمتی مقایسه کرد؟
- امکانات، سن بنا، طبقه و نوع فروشنده چه ارتباطی با قیمت دارند؟
- آیا عباراتی مانند «فوری» و «زیر قیمت» واقعاً با قیمت پایین‌تر همراه هستند؟
- آیا می‌توان محله‌ها و آگهی‌ها را به بخش‌های قابل تفسیر بازار تقسیم کرد؟

منبع داده

منبع اصلی پروژه، دیتاست `divarofficial/real_estate_ads` است که شامل حدود یک میلیون آگهی ناشناس‌شدهٔ املاک دیوار، ۵۷ ستون، ۴۲۱ شهر و داده‌های مربوط به یک بازهٔ شش‌ماهه در سال ۲۰۲۴ است.

<https://github.com/Glyphack/pytse-client>

نمونهٔ کد بارگذاری داده :

```
from datasets import load_dataset
dataset = load_dataset("divarofficial/real_estate_ads")
df = dataset["train"].to_pandas()
```

ستون‌های پرکاربرد این مجموعه شامل اطلاعات زیر هستند:

- شهر و محله؛
- نوع ملک و نوع کاربر؛
- ماه ثبت آگهی؛
- عنوان و توضیحات آگهی؛
- قیمت فروش، رهن و اجاره؛
- مساحت بنا و زمین؛
- تعداد اتاق، طبقه و تعداد طبقات؛

- سال ساخت و وضعیت بازسازی؛
 - امکاناتی مانند آسانسور، پارکینگ، انباری، استخر و جکوزی؛
 - جهت ساختمان و جنس کف؛
 - طول و عرض جغرافیایی.
- به دلیل حجم بالای داده، کارایی کد نیز بخشی از کیفیت اجرای پروژه است. استفاده از عملیات برداری، نوع داده category، پردازش مرحله‌ای و Chunking در صورت نیاز توصیه می‌شود.

مراحل و نظام مسائل

- یک گزارش قابل اعتماد از هوش بازار مسکن و یک معیار قابل مقایسه برای قیمت آگهی‌ها تولید کنید. برای این کار لازم است:
- اعتماد به داده: میزان داده‌های گمشده، تکراری، ناسازگار و غیرعادی را به تفکیک ستون بررسی کنید و برای هر ستون راهبرد پاک‌سازی مستقلی ارائه دهید. استفاده فراگیر از (.) fillna مجاز نیست.
 - پاک‌سازی مقادیر فارسی: ارقام فارسی، نویسه‌های عربی و فارسی و مقادیر متنی موجود در فیلدهای عددی را استاندارد کنید؛ مانند «سه»، «بدون اتاق» یا «قبل از ۱۳۷۰».
 - جداسازی رژیم‌های قیمتی: آگهی‌های فروش، اجاره، رهن کامل و رهن و اجاره را از یکدیگر تفکیک کنید. این گروه‌ها نباید مستقیماً با یکدیگر مقایسه شوند.
 - تشخیص پرت: آگهی‌های دارای قیمت، مساحت یا سال ساخت غیرعادی را شناسایی کنید. قواعد حذف یا نگهداری پرت‌ها باید متناسب با نوع ملک، شهر و رژیم قیمت تعریف و مستند شوند.
 - نرمال‌سازی قیمت: برای آگهی‌های فروش، قیمت پیشنهادی هر مترمربع را محاسبه کنید. برای آگهی‌های رهن و اجاره، یک معیار اجاره معادل یا ودیعه معادل بسازید.

نقشه بازار

میانه قیمت هر مترمربع را به تفکیک شهر و محله محاسبه و مناطق گران و ارزان را شناسایی کنید. در صورت مناسب بودن کیفیت مختصات، نتایج را روی نقشه نمایش دهید.

- عرضه و روند: تعداد آگهی‌ها و روند قیمت پیشنهادی را در ماه‌های موجود به تفکیک شهر، محله و نوع ملک تحلیل کنید.
- محرک‌های قیمت: ارتباط امکانات، مساحت، طبقه، سن بنا، جهت ساختمان و نوع کاربر را با قیمت بررسی کنید.
- تحلیل کیفی متن: عبارت‌هایی مانند «نوساز»، «کلیدنخورده»، «فوری»، «معاوضه» و «زیر قیمت» را از عنوان و توضیحات استخراج و رابطه آن‌ها را با قیمت پیشنهادی بررسی کنید.
- بخش‌بندی بازار: محله‌ها یا آگهی‌ها را بر اساس قیمت، مساحت، امکانات و نوع ملک به بخش‌های قابل تفسیر مانند اقتصادی، میان‌رده، لوکس و زمین سرمایه‌ای تقسیم کنید.

در تبدیل رهن و اجاره می‌توان از یک ضریب رایج بازار، مانند تبدیل هر یک میلیون تومان ودیعه به مبلغ مشخصی از اجاره ماهانه، استفاده کرد؛ اما این ضریب ثابت و قطعی نیست. مقدار انتخاب‌شده باید مستند شود و اثر تغییر آن در قالب تحلیل حساسیت بررسی شود.

محورهای اصلی تحلیل

پس از انجام مراحل ذکرشده، به پرسش‌های زیر پاسخ دهید و برای هر پاسخ، روش تحلیل و دلیل انتخاب آن را توضیح دهید:

- میانه قیمت پیشنهادی هر مترمربع آپارتمان فروشی در تهران، مشهد، کرج و اصفهان چقدر است و گران‌ترین و ارزان‌ترین محله قابل اعتماد هر شهر کدام است؟
- تعداد آگهی‌های فروش مسکونی در ماه‌های موجود چه تغییری کرده و آیا روند قیمت پیشنهادی با روند عرضه هم‌جهت است؟
- کدام شهرها یا محله‌ها بازار داغ‌تر و کدام مناطق بازار سردتری دارند؟
- آسانسور، پارکینگ، انباری، طبقه، سن بنا، تعداد اتاق و جهت ساختمان چه ارتباطی با قیمت هر مترمربع دارند؟
- آیا مشاوران املاک و کاربران شخصی برای واحدهای مشابه قیمت متفاوتی ثبت می‌کنند؟
- آیا عبارت‌هایی مانند «فوری» و «زیر قیمت» واقعاً با قیمت هر مترمربع پایین‌تر همراه‌اند یا صرفاً نقش تبلیغاتی دارند؟
- محله‌ها بر اساس قیمت، مساحت و امکانات در چه بخش‌هایی از بازار قرار می‌گیرند؟

برای بررسی اثر امکانات و ویژگی‌ها، مقایسهٔ خام میانگین‌ها کافی نیست و تفاوت شهر، محله، مساحت، نوع ملک و سن بنا باید تا حد امکان کنترل شود. استفاده از رگرسیون سبک یا مدل‌های قابل تفسیر به عنوان بخش تکمیلی مجاز است.

نکات و هشدارهای مهم

در طول تحلیل به نکات زیر توجه کنید:

- آگهی‌های فروش، اجاره، رهن کامل و رهن و اجاره نباید در یک شاخص قیمتی خام ترکیب شوند. مقدار صفر در اجارهٔ رهن کامل به معنای اجارهٔ رایگان نیست و حالت‌هایی مانند «توافقی»، «مجانی» یا قیمت مقطوع باید جداگانه مدیریت شوند.
- قیمت پیشنهادی آگهی با قیمت نهایی معامله برابر نیست و این محدودیت باید در تمام نتیجه‌گیری‌های قیمتی ذکر شود.
- مقادیر بسیار کوچک یا بزرگ نباید صرفاً با یک قاعدهٔ ثابت مانند سه انحراف معیار حذف شوند؛ پرت‌ها باید با توجه به نوع ملک، موقعیت و دامنهٔ واقعی بازار بررسی شوند.
- نبود مقدار همیشه به معنای خطا نیست؛ برای نمونه، نبود پارکینگ در آگهی زمین می‌تواند طبیعی باشد. قیمت هر مترمربع نیز فقط برای آگهی‌هایی محاسبه شود که مساحت معتبر و متناسب با نوع ملک دارند.
- مختصات جغرافیایی باید از نظر مقادیر گمشده، نقاط خارج از محدوده و دقت مکانی بررسی شوند.
- آگهی‌های تکراری یا ثبت چندبارهٔ یک ملک ممکن است حجم عرضه را بیش از واقع نشان دهند.
- داده‌ها تنها یک بازهٔ شش‌ماهه را پوشش می‌دهند و برای نتیجه‌گیری دربارهٔ روندهای بلندمدت کافی نیستند.
- در صورت نبود زمان حذف آگهی یا وضعیت معامله، «زمان تافروش» قابل اندازه‌گیری نیست و زمان حضور آگهی نباید زمان قطعی فروش تلقی شود.
- این داده‌ها ممکن است نمایندهٔ کامل بازار مسکن ایران نباشند و نتایج باید در محدودهٔ پوشش همین مجموعه داده تفسیر شوند.

خروجی مورد انتظار

در پایان پروژه انتظار می‌رود:

- یک خلاصه مدیریتی دو تا سه صفحه‌ای شامل وضعیت کلی بازار، پنج بازار داغ، پنج بازار سرد، روند عرضه و مهم‌ترین عوامل مرتبط با قیمت ارائه شود.
- یک داشبورد تعاملی در Power BI یا Tableau با قابلیت انتخاب شهر، محله، نوع ملک و ماه ساخته شود و شامل نقشه قیمت هر مترمربع، روند عرضه و قیمت، مقایسه امکانات و بخش‌بندی بازار باشد.
- یک گزارش فنی شامل ممیزی کیفیت داده، روش پاک‌سازی، قواعد تشخیص پرت، نحوه جداسازی رژیم‌های قیمت، روش تبدیل رهن و اجاره، تعریف قیمت هر مترمربع و روش بخش‌بندی بازار ارائه شود.
- محدودیت‌هایی مانند تفاوت قیمت پیشنهادی و قیمت معامله، پوشش شش ماهه، مقادیر گم‌شده، آگهی‌های تکراری و محدودیت نمایندگی داده‌ها به صورت شفاف بیان شوند.
- پیشنهادهای اقدام‌پذیر برای توسعه محصول هوش بازار یا نسخه اولیه سامانه قیمت‌گذاری خودکار ارائه شود.

الزامات کلی، نحوه ارزیابی و زمان‌بندی

- فایل تمامی کدهای پروژه به صورت کامل و قابل اجرا به همراه خروجی‌ها ارسال شود.
- مستندات شامل توضیح کامل مراحل انجام پروژه، روش تحلیل و پاسخ تمامی پرسش‌ها ارائه شود.
- یک ویدئوی دمو و ارائه (حداکثر ۱۰ دقیقه) تهیه شود که در آن روند کار، نتایج و خروجی‌های پروژه توضیح داده شود.
- در صورت استقرار داشبورد، وب‌اپلیکیشن یا API، لینک پروژه نیز ارسال شود.

پروژه‌ها بر اساس صحت تحلیل، کیفیت کد، مستندسازی، مصورسازی، کیفیت ارائه و خلاقیت در تحلیل ارزیابی خواهند شد.

آكادمي همراه اول